

Reporte ejecutivo

Análisis Predictivo en Finanzas

MBD0011 - Magíster en Business Analytics

Daniel Avello - Felipe Valdivia - Roberto Sepúlveda

10 de mayo de 2026

Resumen

Este informe presenta los resultados del examen de Análisis Predictivo en Finanzas. El trabajo se organizó en tres partes: simulaciones para estudiar regresión espuria, ejercicios de predictibilidad con *commodity currencies* y una aplicación de Box-Jenkins al GDP de Reino Unido.

En la Parte 1 se generaron series independientes bajo distintos niveles de persistencia. La idea fue revisar qué pasa cuando se estima una regresión entre variables que, por construcción, no tienen relación. En el caso estacionario los falsos rechazos fueron acotados, aunque no desaparecieron; con alta persistencia aumentaron; y con caminatas aleatorias la inferencia usual rechazó en las diez regresiones. HAC ayudó a reducir parte del problema, pero no corrigió el efecto de trabajar con series con raíz unitaria.

En la Parte 2 se evaluó la hipótesis de *commodity currencies*. La evidencia dentro de muestra fue favorable en algunos casos, especialmente en aluminio y en especificaciones que incorporan el peso chileno. Sin embargo, al pasar a ejercicios fuera de muestra, los modelos con tipo de cambio no dominaron de forma estable al AR(1) ni a otros benchmarks simples. La evaluación económica mediante MDA, trading y portafolio tampoco mostró ganancias robustas. Por eso, la conclusión de esta parte es prudente: hay señales predictivas en casos específicos, pero no son fáciles de explotar de manera sistemática.

En la Parte 3 se aplicó la metodología Box-Jenkins. El GDP en nivel no rechazó raíz unitaria, mientras que la primera diferencia logarítmica sí presentó un comportamiento estacionario. Entre los modelos evaluados, el ARIMA(1,1,1) fue seleccionado por criterios de información, significancia de parámetros y diagnóstico de residuos.

La lectura general es que no basta con encontrar coeficientes significativos. Antes de afirmar que un modelo predice, hay que revisar estacionariedad, comparar contra benchmarks simples, evaluar fuera de muestra y preguntarse si la señal tiene utilidad económica.

1 Introducción

El examen trabaja con un problema bastante práctico: en series financieras es fácil encontrar relaciones que parecen predictivas, pero que después no se sostienen al revisar mejor los datos. Por eso, el informe no se centra solo en reportar regresiones, sino en revisar qué tan confiables son esas relaciones cuando se consideran estacionariedad, errores robustos, evaluación fuera de muestra y valor económico.

Bajo esa lógica, el informe se divide en tres partes. La primera usa simulaciones para mostrar cómo aparecen relaciones espurias cuando las series son persistentes o tienen raíz unitaria. La segunda evalúa si algunos tipos de cambio contienen información útil para anticipar retornos de commodities. La tercera aplica la metodología Box-Jenkins para modelar el GDP de Reino Unido.

La idea no es forzar una conclusión optimista sobre predictibilidad. De hecho, varios resultados muestran que la evidencia se debilita cuando se exige validación fuera de muestra o cuando se evalúa si la señal sirve para tomar decisiones económicas. Por eso se presentan tanto los resultados favorables como los casos donde los modelos no logran superar benchmarks simples.

2 Simulaciones y Regresión Espuria

2.1 Diseño del ejercicio

Se generaron veinte procesos independientes en cada escenario. Los diez primeros se definieron como $Y_1, \dots, Y_{10}$ y los diez restantes como $X_1, \dots, X_{10}$. Luego se estimaron diez regresiones de la forma:

$$Y_{i,t} = c + kX_{i,t} + u_{i,t}, \quad i = 1, \dots, 10. \quad (1)$$

Como las variables X_i e Y_i fueron generadas de forma independiente, el valor teórico de k es cero. Por lo tanto, cada rechazo de $H_0 : k = 0$ corresponde a un falso rechazo. La comparación se hizo usando errores estándar usuales y errores estándar HAC.

Se revisaron tres escenarios: AR(1) estacionario con $b = 0,6$, AR(1) altamente persistente con $b = 0,97$ y caminata aleatoria con $b = 1$. El interés no está solo en cada regresión individual, sino en ver cómo cambia la frecuencia de rechazos cuando aumenta la persistencia.

2.2 Resultados por escenario

Cuadro 1: Resultados de regresión: AR(1) estacionario ($b = 0,6$)

Regresión	$\hat{k}$	p-val usual	Sig. usual	p-val HAC	Sig. HAC	R^2
Y1 ~ X1	0.0966	0.0030	Sí	0.0356	Sí	0.0088
Y2 ~ X2	-0.0212	0.4925	No	0.6301	No	0.0005
Y3 ~ X3	0.0158	0.6445	No	0.7331	No	0.0002
Y4 ~ X4	0.0651	0.0403	Sí	0.1148	No	0.0042
Y5 ~ X5	0.0286	0.3711	No	0.5178	No	0.0008
Y6 ~ X6	0.0349	0.2996	No	0.4614	No	0.0011
Y7 ~ X7	-0.0012	0.9699	No	0.9808	No	0.0000
Y8 ~ X8	0.0511	0.1027	No	0.2204	No	0.0027
Y9 ~ X9	-0.0729	0.0285	Sí	0.1444	No	0.0048
Y10 ~ X10	-0.1091	0.0007	Sí	0.0034	Sí	0.0115

En el caso estacionario, la inferencia usual rechaza 4 de 10 veces y HAC rechaza 2 de 10. El porcentaje usual es alto para un ejercicio al 10 %, pero hay que leerlo con cuidado porque el número de regresiones es pequeño. Lo importante es que los R^2 son muy bajos y no aparece una relación económica real entre las series.

Como complemento, se repitió el experimento muchas veces para que la conclusión no dependa solo de una corrida puntual de diez regresiones. La Figura 1 resume esa repetición. En el caso con $b = 0,6$, OLS suele rechazar más que el 10 % nominal: la mayor parte de las simulaciones queda entre 20 % y 40 % de rechazos. Con HAC, la distribución se mueve hacia valores más bajos y queda más cerca del nivel esperado, aunque todavía hay variación entre corridas. Esto confirma que el primer resultado de la tabla debe interpretarse con cautela: el problema existe, pero es bastante menos severo que en los escenarios más persistentes.




Figura 1: Distribución de rechazos en simulaciones repetidas, $b = 0,6$

La lectura general de esta primera simulación es que, aun trabajando con procesos estacionarios, la dependencia temporal puede afectar la inferencia si se usan errores estándar usuales. HAC mejora el comportamiento de los rechazos, pero no debe leerse como una solución automática para cualquier especificación.

Cuadro 2: Resultados de regresión: AR(1) altamente persistente ($b = 0,97$)

Regresión	$\hat{k}$	p-val usual	Sig. usual	p-val HAC	Sig. HAC	R^2
Y1 ~ X1	-0.0956	0.0188	Sí	0.4146	No	0.0055
Y2 ~ X2	-0.0028	0.9365	No	0.9810	No	0.0000
Y3 ~ X3	-0.0654	0.1237	No	0.6442	No	0.0024
Y4 ~ X4	0.1037	0.0003	Sí	0.1858	No	0.0130
Y5 ~ X5	-0.0526	0.1726	No	0.6325	No	0.0019
Y6 ~ X6	0.2289	0.0000	Sí	0.2220	No	0.0185
Y7 ~ X7	0.0294	0.3291	No	0.6882	No	0.0010
Y8 ~ X8	-0.0091	0.7592	No	0.9179	No	0.0001
Y9 ~ X9	-0.2760	0.0000	Sí	0.0003	Sí	0.0846
Y10 ~ X10	-0.1381	0.0000	Sí	0.0607	Sí	0.0291

Al aumentar la persistencia a $b = 0,97$, la inferencia usual rechaza 5 de 10 veces. HAC vuelve a dejar solo 2 rechazos. En este caso las series siguen siendo estacionarias, pero la persistencia genera trayectorias largas que pueden parecer tendencias locales. Ese comportamiento distorsiona la inferencia usual y aumenta la frecuencia de falsos rechazos.




Figura 2: Distribución de rechazos en simulaciones repetidas, $b = 0,97$

La Figura 2 muestra que este no es un caso aislado. Cuando b está cerca de uno, la distribución de

rechazos con OLS se desplaza fuertemente hacia la derecha: muchas simulaciones terminan con tasas de rechazo muy superiores al 10 %. HAC reduce el problema, pero la dispersión sigue siendo alta y la tasa de rechazo todavía queda lejos de un comportamiento ideal. En términos prácticos, la alta persistencia vuelve mucho más riesgoso interpretar significancias como evidencia de relación predictiva.

Cuadro 3: Resultados de regresión: caminata aleatoria

Regresión	$\hat{k}$	p-val usual	Sig. usual	p-val HAC	Sig. HAC	R^2
Y1 ~ X1	-0.5218	0.0000	Sí	0.0001	Sí	0.1849
Y2 ~ X2	-0.1082	0.0000	Sí	0.2221	No	0.0204
Y3 ~ X3	1.0138	0.0000	Sí	0.0000	Sí	0.5859
Y4 ~ X4	0.0713	0.0351	Sí	0.4228	No	0.0044
Y5 ~ X5	0.4358	0.0000	Sí	0.0000	Sí	0.2731
Y6 ~ X6	0.5454	0.0000	Sí	0.0012	Sí	0.2204
Y7 ~ X7	0.3302	0.0000	Sí	0.0000	Sí	0.4135
Y8 ~ X8	0.2598	0.0000	Sí	0.0009	Sí	0.1209
Y9 ~ X9	0.2076	0.0000	Sí	0.0118	Sí	0.0582
Y10 ~ X10	-1.0607	0.0000	Sí	0.0000	Sí	0.7014

El tercer escenario corresponde a una caminata aleatoria porque, al fijar $b = 1$ y $a = 0$, el AR(1) queda como $Y_t = Y_{t-1} + \varepsilon_t$. Es el caso donde el problema se ve con mayor claridad. La inferencia usual rechaza en el 100 % de las regresiones y HAC todavía rechaza en el 80 %. Además, varios R^2 son altos. Esto es engañoso, porque las series fueron generadas de forma independiente.




Figura 3: Regresiones entre caminatas aleatorias independientes




Figura 4: Distribución de rechazos en simulaciones repetidas, $b = 1$

La Figura 4 cierra el patrón. Con $b = 1$, tanto OLS como HAC concentran gran parte de las simulaciones en tasas de rechazo muy altas. La diferencia es que HAC baja algo la frecuencia, pero no cambia la conclusión de fondo: al trabajar con caminatas aleatorias independientes, la regresión en niveles queda mal planteada y puede producir significancia casi por construcción. Por eso el resultado no debe interpretarse como predictibilidad, sino como evidencia de regresión espuria.

Cuadro 4: Resumen consolidado de simulaciones

Escenario	b	Nivel	% usual	% HAC	R^2 prom.
AR(1) estacionario	0.60	10 %	40.0	20.0	0.0035
AR(1) altamente persistente	0.97	10 %	50.0	20.0	0.0156
Random walk	1.00	5 %	100.0	80.0	0.2583

2.3 Interpretación de la Simulaciones y Regresión Espuria

Si $k = 0$ y se trabaja al 10 % de significancia, en condiciones estándar se esperaría rechazar cerca de 10 % de las veces. Las tablas muestran el resultado de una corrida puntual, mientras que las figuras de simulación repetida permiten ver el patrón general. En ambos casos la conclusión es la misma: a medida que aumenta la persistencia, crece la probabilidad de encontrar significancia donde no existe relación real.

La lección práctica es directa: HAC ayuda, pero no arregla una regresión mal planteada con series no estacionarias. Antes de estimar relaciones predictivas en finanzas, conviene revisar raíz unitaria y transformar las series cuando corresponde.

3 Commodity Currencies

3.1 Datos, transformaciones y estacionariedad

La Parte 2 se trabajó con frecuencia mensual desde 1999M09. La base contiene tipos de cambio y commodities como aluminum, copper, lead, nickel, tin y LMEX. El enunciado menciona zinc, pero la base disponible no incluye esa columna; por eso el análisis se hizo con las series efectivamente presentes. Primero se revisaron niveles, logaritmos y retornos. En niveles y logaritmos, las series muestran alta persistencia. En retornos, la persistencia baja de forma importante y las series se ven más compatibles con estacionariedad.




Figura 5: Tipo de cambio chileno en nivel: serie, ACF y PACF




Figura 6: Tipo de cambio chileno en logaritmo: serie, ACF y PACF




Figura 7: Retorno logarítmico del tipo de cambio chileno: serie, ACF y PACF

El cambio entre las figuras es claro. En nivel y logaritmo, la ACF cae lentamente. En retorno, las autocorrelaciones quedan mucho más cerca de cero. Por eso las regresiones se realizaron con diferencias logarítmicas.

Cuadro 5: Resultados seleccionados del test ADF

Serie	Transformación	ADF stat	p-value	Rechaza RU 5 %
Chile	Nivel	-1.4589	0.5537	No
Chile	Logaritmo	-1.4982	0.5344	No
Chile	Retorno log	-15.4096	0.0000	Sí
Australia	Nivel	-1.5188	0.5242	No
Australia	Retorno log	-15.0744	0.0000	Sí
Copper	Nivel	-2.0839	0.2510	No
Copper	Retorno log	-8.6658	0.0000	Sí
Aluminum	Nivel	-2.2837	0.1773	No

Los ADF confirman la lectura visual: precios y tipos de cambio en nivel no rechazan raíz unitaria, mientras que los retornos sí lo hacen. Esto es consistente con trabajar los modelos predictivos en retornos.




Figura 8: Histogramas de retornos logarítmicos

En los histogramas se observan diferencias respecto de una normal perfecta en la mayoría de las series. En esta muestra, aluminum es la única serie donde no se rechaza normalidad al 5 %. En el resto aparecen desviaciones que son comunes en retornos financieros: shocks grandes, asimetrías o colas más pesadas. Por eso, los resultados basados en inferencia tradicional deben leerse con cautela y complementarse con errores robustos y evaluación fuera de muestra.

3.2 Modelo CRR dentro de muestra

La especificación de Chen, Rogoff y Rossi agrega un rezago del tipo de cambio a un AR(1) del retorno del commodity:

$$\Delta \log(C_t) = c + \rho \Delta \log(C_{t-1}) + \beta \Delta \log(TC_{t-1}) + \varepsilon_t. \quad (2)$$

En los resultados seleccionados, la evidencia más clara aparece en aluminum. Para Chile, el coeficiente del tipo de cambio es -0.2883 y tiene p-value 0.0136. Para Australia, el coeficiente es -0.3199 y tiene p-value 0.0061. En copper y LMEX no se observa significancia al 5 %.

Cuadro 6: Resultados predictivos in-sample tipo CRR

Commodity	TC	ρ AR	p-val ρ	Sig. ρ	β_{TC}	p-val β	Sig. β	ΔR^2
Copper	Chile	0.1166	0.1106	No	-0.2067	0.1962	No	0.0066
Copper	Australia	0.1190	0.1195	No	-0.1643	0.2938	No	0.0044
Aluminum	Chile	-0.0284	0.6750	No	-0.2883	0.0136	Sí	0.0245
Aluminum	Australia	-0.0650	0.3686	No	-0.3199	0.0061	Sí	0.0302
LMEX	Chile	0.0835	0.2641	No	-0.2114	0.1157	No	0.0098
LMEX	Australia	0.0716	0.3715	No	-0.2041	0.1300	No	0.0091

La interpretación es acotada. No se observa que todos los tipos de cambio predigan todos los commodities. Más bien, la evidencia aparece en casos puntuales, especialmente aluminum.

3.3 Errores HAC y especificaciones Pincheira-Hardy

Al repetir el ejercicio con errores HAC, la conclusión principal se mantiene, aunque los p-values aumentan. Aluminum sigue siendo significativo tanto con Chile como con Australia, mientras que copper y LMEX no muestran evidencia robusta.

Cuadro 7: Resultados in-sample con errores HAC

Commodity	TC	ρ AR	p-val ρ	Sig. ρ	β_{TC}	p-val β	Sig. β	ΔR^2
Copper	Chile	0.1166	0.2201	No	-0.2067	0.2177	No	0.0066
Copper	Australia	0.1190	0.2351	No	-0.1643	0.3715	No	0.0044
Aluminum	Chile	-0.0284	0.7568	No	-0.2883	0.0342	Sí	0.0245
Aluminum	Australia	-0.0650	0.5406	No	-0.3199	0.0414	Sí	0.0302
LMEX	Chile	0.0835	0.3992	No	-0.2114	0.1418	No	0.0098
LMEX	Australia	0.0716	0.5015	No	-0.2041	0.2009	No	0.0091

La especificación Pincheira-Hardy incorpora dos rezagos del tipo de cambio:

$$\Delta \log(C_t) = c + \rho \Delta \log(C_{t-1}) + \beta_1 \Delta \log(TC_{t-1}) + \beta_2 \Delta \log(TC_{t-2}) + \varepsilon_t. \quad (3)$$

Para el peso chileno, el test conjunto $H_0 : \beta_1 = \beta_2 = 0$ entrega evidencia para tin, LMEX, lead, copper y aluminum. Nickel es el caso donde la evidencia es más débil. Esto sugiere que parte de la información predictiva puede estar distribuida en más de un rezago.

También se estimó una versión restringida usando la suma de los dos rezagos del tipo de cambio. Esa restricción reduce el número de parámetros. Para Chile, la pérdida de R^2 es baja en la mayoría de los commodities: tin, copper y aluminum caen alrededor de 0.001 a 0.002. La mayor caída aparece en lead. Por eso, la restricción parece razonable cuando se busca parsimonia, aunque no necesariamente domina en todos los casos.

3.4 Evaluación fuera de muestra

La evaluación fuera de muestra es más exigente que el ajuste in-sample. En lugar de usar toda la muestra para estimar, se separa una ventana de estimación y otra de evaluación. Luego se pronostica un paso adelante, actualizando los parámetros con ventanas recursivas y rodantes.

En el setup 30%-70%, el modelo PH con dos rezagos no supera al AR(1) para copper con Chile en las ventanas recursiva y rodante. En algunos casos, el zero forecast presenta menor ECM.

Cuadro 8: Ejemplos fuera de muestra: división 30 %-70 %

Commodity	TC	Ventana	Modelo	ECM	R^2_{OOS}	p-val DM	Mejor que AR(1)
Copper	Chile	Recursive	PH dos rezagos	0.0064	-0.0077	0.7801	No
Copper	Chile	Recursive	AR(1)	0.0064	0.0000	—	—
Copper	Chile	Recursive	Prom. histórico	0.0064	-0.0087	0.8717	No
Copper	Chile	Recursive	Zero forecast	0.0063	0.0066	0.8911	Sí
Copper	Chile	Rolling	PH dos rezagos	0.0065	-0.0126	0.6512	No
Copper	Chile	Rolling	AR(1)	0.0065	0.0000	—	—
Copper	Chile	Rolling	Zero forecast	0.0063	0.0184	0.7578	Sí

En el setup 50 %-50 %, también aparecen benchmarks simples con buen desempeño. Para copper con Chile, el promedio histórico y el zero forecast superan al AR(1) y tienen diferencias significativas en algunos casos, mientras que PH no mejora al AR(1).

Cuadro 9: Ejemplos fuera de muestra: división 50 %-50 %

Commodity	TC	Ventana	Modelo	ECM	R^2_{OOS}	p-val DM	Mejor que AR(1)
Copper	Chile	Recursive	PH dos rezagos	0.0043	-0.0238	0.5848	No
Copper	Chile	Recursive	AR(1)	0.0042	0.0000	—	—
Copper	Chile	Recursive	Prom. histórico	0.0037	0.1020	0.0466	Sí
Copper	Chile	Recursive	Zero forecast	0.0036	0.1287	0.0225	Sí
Copper	Chile	Rolling	PH dos rezagos	0.0044	-0.0246	0.5696	No
Copper	Chile	Rolling	Prom. histórico	0.0038	0.1098	0.0358	Sí
Copper	Chile	Rolling	Zero forecast	0.0036	0.1498	0.0107	Sí

La diferencia entre in-sample y out-of-sample es una de las partes más importantes del ejercicio. Dentro de muestra se encuentran señales, pero fuera de muestra esas señales no dominan de manera estable. Esto puede deberse a inestabilidad de parámetros, sobreajuste o simplemente a que la señal predictiva es débil frente al ruido de los retornos financieros.

3.5 MDA, trading y portafolio

La Mean Directional Accuracy evalúa si el modelo acierta la dirección del retorno. En los casos reportados, la MDA queda cerca del 50 % o por debajo. Por ejemplo, el modelo PH con copper-Chile obtiene 0.4597 en ventana recursiva y 0.4677 en ventana rodante. Ninguno supera significativamente el benchmark de suerte pura.

Cuadro 10: Ejemplos de Mean Directional Accuracy

Commodity	TC	Ventana	Modelo	MDA	p-value unilateral	Supera 50 %
Copper	Chile	Recursive	PH dos rezagos	0.4597	0.7957	No
Copper	Chile	Recursive	AR(1)	0.4194	0.9618	No
Copper	Chile	Recursive	Prom. histórico	0.5081	0.4222	No
Copper	Chile	Rolling	PH dos rezagos	0.4677	0.7570	No
Copper	Chile	Rolling	AR(1)	0.4597	0.8188	No
Copper	Australia	Recursive	PH dos rezagos	0.4194	0.9586	No

La estrategia de trading entrega una conclusión similar. Los retornos medios no son estadísticamente significativos en los modelos PH reportados. Por lo tanto, una mejora marginal en error de predicción no alcanza para construir una señal económica clara.

Cuadro 11: Ejemplos de estrategia de trading

Commodity	TC	Ventana	Modelo	Ret. medio	Ret. anual	p-value HAC	Significativo
Copper	Chile	Recursive	PH dos rezagos	0.0007	0.0088	0.8731	No
Copper	Chile	Recursive	AR(1)	-0.0052	-0.0622	0.2671	No
Copper	Chile	Recursive	Prom. histórico	-0.0015	-0.0183	0.7513	No
Copper	Chile	Rolling	PH dos rezagos	0.0011	0.0133	0.8137	No
Copper	Chile	Rolling	AR(1)	-0.0042	-0.0505	0.4175	No
Copper	Australia	Recursive	PH dos rezagos	-0.0042	-0.0505	0.3820	No

El bonus de portafolio se incluyó para revisar si la señal predictiva mejora una decisión de inversión. Se usó una tasa libre de riesgo anual de 3 %, costos de transacción y dos niveles de aversión al riesgo ($\gamma = 3$ y $\gamma = 5$). Los resultados no muestran una ventaja consistente: en varios casos el Sharpe es negativo y los excesos medios no son significativos.

Cuadro 12: Ejemplos de portafolio tipo Neely et al.

Commodity	TC	Modelo	γ	Ret. anual	Vol. anual	Sharpe	CER	p-value HAC
Copper	Chile	PH dos rezagos	3	0.0228	0.2171	-0.0313	-0.0479	0.9123
Copper	Chile	PH dos rezagos	5	0.0094	0.1820	-0.1108	-0.0734	0.7053
Copper	Chile	AR(1)	3	-0.0628	0.1831	-0.5043	-0.1131	0.0799
Copper	Chile	AR(1)	5	-0.0531	0.1371	-0.6036	-0.1001	0.0380
Copper	Chile	Prom. histórico	3	-0.0125	0.1481	-0.2846	-0.0454	0.3155
Copper	Chile	Zero forecast	3	0.0296	0.0000	—	0.0296	—

3.6 Bonus 2: paradoja del MSPE

El segundo bonus revisa la paradoja del MSPE. Esta aparece cuando un modelo tiene peor error cuadrático medio que el benchmark, pero mayor correlación con la variable objetivo. En los resultados hay casos donde PH tiene peor ECM que AR(1), pero mayor correlación. Sin embargo, las diferencias de correlación no son significativas al 5 %.

Cuadro 13: Ejemplos de paradoja del MSPE

Commodity	TC	Ventana	Modelo	ECM modelo	ECM AR(1)	Δ corr.	p-val boot	Sig. 5 %
Copper	Chile	Recursive	PH dos rezagos	0.0043	0.0042	0.0677	0.2953	No
Copper	Chile	Rolling	PH dos rezagos	0.0044	0.0043	0.0569	0.3724	No
Copper	Australia	Recursive	PH dos rezagos	0.0042	0.0042	0.0281	0.3834	No
Copper	Australia	Rolling	PH dos rezagos	0.0043	0.0043	0.0135	0.6537	No

Esto sirve para no depender de una sola métrica. El MSPE castiga errores de magnitud, mientras que la correlación mide comovimiento. Un modelo puede seguir mejor la dirección general y aun así equivocarse más en escala. En este caso, la paradoja funciona más como advertencia metodológica que como evidencia fuerte a favor del modelo PH.

3.7 Conclusión de Commodity Currencies

La evidencia es mixta. Dentro de muestra aparecen señales compatibles con la literatura de *commodity currencies*, especialmente en aluminio y en algunas especificaciones con el peso chileno. Fuera de muestra, la señal no domina de manera estable a benchmarks simples. Además, MDA, trading y portafolio no

entregan beneficios significativos. La conclusión más razonable es que la predictibilidad existe en algunos casos, pero es frágil y difícil de explotar de manera sistemática.

4 Metodología Box-Jenkins

4.1 Diagnóstico inicial

La serie GDP de Reino Unido muestra una tendencia clara en nivel. Su ACF cae lentamente y la PACF presenta un primer rezago dominante, lo que sugiere no estacionariedad. El test ADF confirma esta lectura: para GDP en nivel el p-value es 0.8621, por lo que no se rechaza raíz unitaria.




Figura 9: GDP en nivel: serie, ACF y PACF

Al tomar la primera diferencia logarítmica, la serie cambia de comportamiento. La tendencia desaparece y las autocorrelaciones son menores. El ADF rechaza raíz unitaria con p-value 0.0023, por lo que el GDP se trata como una serie integrada de orden uno.




Figura 10: Primera diferencia logarítmica del GDP: serie, ACF y PACF

Cuadro 14: Test ADF para GDP

Serie	ADF stat	p-value	Rechaza RU 5 %
GDP nivel	-0.6381	0.8621	No
$\Delta \log(GDP)$	-3.8676	0.0023	Sí

4.2 Selección de modelos ARIMA

Como la serie es $I(1)$, se estimaron modelos $ARIMA(p, 1, q)$. Se compararon cuatro candidatos. El $ARIMA(1, 1, 1)$ obtiene el menor AIC y el menor BIC. Además, su Durbin-Watson es 2.0677, cercano a 2, lo que es consistente con baja autocorrelación residual.

Cuadro 15: Comparación de modelos ARIMA candidatos

Modelo	AIC	BIC	Log-Likelihood	Durbin-Watson
ARIMA(1,1,1)	-527.4905	-520.6191	266.7453	2.0677
ARIMA(1,1,0)	-522.6666	-518.0857	263.3333	2.1871
ARIMA(2,1,1)	-519.3491	-510.1873	263.6746	2.1896
ARIMA(0,1,1)	-504.4093	-499.8284	254.2046	1.4687

La significancia de parámetros también favorece al ARIMA(1,1,1). El componente AR(1) es significativo y el MA(1) también. En cambio, en ARIMA(2,1,1) los parámetros principales no son significativos, por lo que el mayor número de parámetros no parece justificado.

Cuadro 16: Significancia de parámetros ARIMA

Modelo	Parámetro	Coefficiente	p-value	Sig. 5 %
ARIMA(1,1,0)	ar.L1	0.6793	0.0000	Sí
ARIMA(0,1,1)	ma.L1	0.5172	0.0000	Sí
ARIMA(1,1,1)	ar.L1	0.8739	0.0000	Sí
ARIMA(1,1,1)	ma.L1	-0.3565	0.0183	Sí
ARIMA(2,1,1)	ar.L1	0.2593	0.8201	No
ARIMA(2,1,1)	ar.L2	0.3488	0.6576	No
ARIMA(2,1,1)	ma.L1	0.3934	0.7372	No

4.3 Diagnóstico de residuos

Después de seleccionar ARIMA(1,1,1), se revisaron los residuos. La ACF y PACF residual no muestran autocorrelaciones relevantes fuera de las bandas. El test de Ljung-Box tampoco rechaza autocorrelación residual en los rezagos evaluados.




Figura 11: Diagnóstico de residuos del modelo ARIMA(1,1,1)

Cuadro 17: Test Ljung-Box sobre residuos

Rezago	LB Statistic	p-value
4	0.0025	1.0000
8	0.0043	1.0000
12	0.0057	1.0000

Con esto, el modelo seleccionado cumple razonablemente con el diagnóstico Box-Jenkins dentro de muestra. La serie fue diferenciada para lograr estacionariedad, se estimaron candidatos, se eligió por criterios de información y se revisaron residuos.




Figura 12: Crecimiento observado y estimado por ARIMA(1,1,1)




Figura 13: Residuos de estimación del modelo ARIMA(1,1,1)

4.4 Comentario sobre pronóstico

El ajuste dentro de muestra no debe confundirse con un ejercicio predictivo completo. Para proyectar GDP hacia adelante, el modelo tendría que evaluarse fuera de muestra o con un esquema de validación temporal. Además, la muestra termina en 1998, por lo que pronosticar hasta 2022-2030 exigiría asumir

estabilidad de parámetros por un período demasiado largo. Ese supuesto no es inocente en una serie macroeconómica.




Figura 14: PIB Reino Unido en log observado y estimado por ARIMA(1,1,1)

El modelo tampoco incorpora información externa, como inflación, tasas de interés o cambios estructurales. Por eso, si el objetivo fuera pronosticar hacia adelante, habría que separar una ventana de evaluación, calcular métricas como RMSE o MAE y comparar contra benchmarks simples. Para el objetivo del examen, el modelo es defendible como ejercicio Box-Jenkins dentro de muestra; para usarlo como pronóstico real, faltaría esa validación adicional.

4.5 Conclusión de la Metodología Box-Jenkins

El GDP se comporta como una serie $I(1)$. Una vez tomada la primera diferencia logarítmica, el modelo ARIMA(1,1,1) captura adecuadamente la dependencia temporal observada. El modelo no garantiza buen pronóstico futuro por sí solo, pero sí es una especificación defendible para el análisis solicitado.

5 Conclusión final

El trabajo deja tres resultados principales. Primero, la estacionariedad no es un trámite previo: cuando se ignora, la inferencia puede mostrar relaciones que no existen. Segundo, la evidencia dentro de muestra debe tomarse con cautela, porque puede desaparecer al evaluar fuera de muestra. Tercero, una señal estadística no siempre se transforma en una decisión económica útil.

La Parte 1 mostró el riesgo de regresión espuria. La Parte 2 mostró que la predictibilidad con *commodity currencies* aparece en algunos casos, pero no de forma robusta al cambiar el criterio de evaluación. La Parte 3 mostró cómo aplicar Box-Jenkins de manera ordenada para identificar, estimar y diagnosticar un modelo ARIMA.

En conjunto, la conclusión es moderada: hay señales predictivas en ejercicios específicos, pero no son lo suficientemente estables como para afirmar una capacidad predictiva general. En finanzas, comparar contra benchmarks simples y evaluar fuera de muestra termina siendo tan importante como obtener un buen ajuste dentro de muestra.